SciencePal · AI4Science Hackathon 2026

科研论文核查员

Paper Reference Verifier

在 SciencePal 沙箱里逐条联网核验参考文献，用可追溯证据替代“凭记忆猜测”

DOI 真伪核验

题录逐字段比对

撤稿识别

方法学沙箱复算

主办：香港城市大学 HKAI-Sci | 参赛：邹亮明 · 邹晶晶 | 提交截止：2026-10-31

问题：模型凭记忆无法可靠识别引用幻觉

这不是小概率问题，而是科研可信度的系统性风险；右侧为我们 48 条金标准的实测

为什么需要外部证据

- **编造 DOI** 大模型“编造”参考文献， DOI 格式逼真，肉眼难辨。
- **题录错配** 真实 DOI 配错作者、年份、期刊或卷期页，张冠李戴。
- **撤稿未披露** 被撤稿论文仍被当作正常文献引用，污染证据链。
- **人工成本高** 逐条查库、核对、查撤稿极耗时，审稿难规模化。

实测：纯模型只能猜“格式规律”（48 条）

0.62

幻觉 DOI 检测 F1 仅 0.62，误报 8 次、漏报 3 次

8 次误报

用臆想的“期刊 DOI 格式规则”冤枉真实文献

3 次漏报

漏掉的恰是格式最规范、最危险的伪造 DOI

结论：没有外部证据，模型无法可靠区分“真”与“逼真”

问题的量级（公开文献，非自测）

> 70%

受访研究者曾尝试却无法复现他人的实验

Nature 2016 reproducibility survey, n=1576

1 万 +

2023 年撤稿论文数创历史纪录，撤稿库累计约 5.5 万条

Nature 2023； Retraction Watch / Crossref

18%

GPT-4 生成的引用为编造，另有 24% 真实引用有实质错误

Sci Rep 2023;13:14045

方案：三层核查 + 证据留痕

创新点是工作流与工程约束，而不是更大的模型



设计原则一 · 强制取证

每条引用必须联网查询 Crossref，禁止凭记忆作答；

HTTP 状态、来源 URL、沙箱复算脚本全部留痕，可逐条复核。

设计原则二 · 人机协同

不确定即标记 suspect 并交人工复核，不武断下结论；

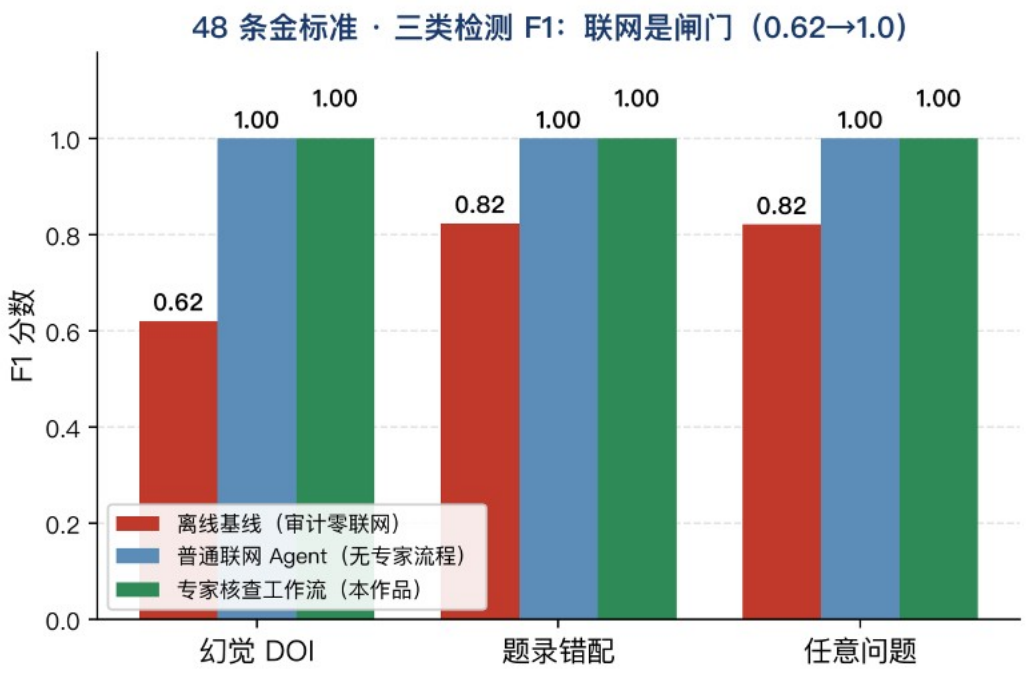
定位为审稿 / 作者自检助手，不替代同行评议。

SciencePal 的作用：提供 Agent 运行环境、可联网沙箱与工具编排，并保留可回放的运行记录；核查的每一次取证都在平台内真实执行，不是用它写文案或做 PPT 。

两个主结果：联网是能力闸门，代码级 guardrail 保证交付可解析

48 条三方对照 + 6 例注入干预前后对照；回溯审计 35 个 run：专家 5/5、普通联网 2/4、离线 0/7 合规

主结果① 能力闸门：一联网，F1 0.62→1.0、误报 23→0



主结果② 代码级 guardrail：同一 Agent 加 / 不加，交付可用 6/6 vs 4/6

交付可用率（6 例注入）	专家	6/6
可解析且结构 / 覆盖 / 证据 / 自洽四类校验全过	普通	4/6
契约违规（注入）	专家	0 次
漏条目、改 schema 各 1 例，F1 直接归零	普通	2 次
运行时拦截 / 自动修复	专家	1 / 4
save_memory 一出现即 stop 并纠正续跑	普通	0 / 0
校验器检测力（故障注入）	专家	18/18
6 类失败模式 × 3 来源，同一套代码判定	普通	无此机制

如何读这两个结果：诚实、不设弱对手

- H1 成立：联网是硬闸门，F1 0.62→1.0、误报 23→0；H2 阴性：强模型上专家流程不额外提高 F1，不宣称更准。
- 交付契约下沉到代码：平台关不掉记忆工具（9 种写法实测全无效），故拦截在运行时执行；注入实验把不可解析的交付从 2/6 降到 0/6。
- 局限：干净 48 条与 36 条规模上 guardrail 0 次干预、F1 不变；stop 只能中断不能撤销记忆（两组均 1/6）；修复代价 token +82%；注入 n=6 为定性证据。
- 泛化：换 deepseek-v4-pro 复现 4/4、F1 1.000；真实已发表论文的 50 条书目检出 4/4、误报 0。

真实可复现：打开公开链接即见全过程

免登录只读回放，完整保留沙箱执行轨迹与最终报告

主演示 · 一屏四态

4 条引用分别命中：真实放行 / 404 篡改 DOI / 年份错配 / STAP 撤稿

sciencepal.ai/share/ee4068d7-07e5-4a27-9af7-1f3c50fedcaa

案例 A · 撤稿识别

识别被当正常引用的 STAP 论文，定位官方撤稿通知 DOI

sciencepal.ai/share/f6f8746c-3350-48f1-ac58-d0150e135ac1

案例 B · 统计复算

沙箱 scipy 复算发现 p 值与数据矛盾：报告 0.03/0.04，实算 0.206/0.138

sciencepal.ai/share/8de1f3cc-cde0-41ad-a2b5-b3b9af5a004b

随附可复现材料

- 代码仓库：评测集 / 跑批 / 评分 / 审计 / guardrail 全脚本
- 一键复现： run_batch + run_naive → export → audit
- 三方对照报告、逐条结果、 SSE 审计、 Layer-2 案例
- guardrail 协议与故障注入（可用率 6/6 vs 4/6 ）
- 原创性与资源使用声明

未来工作

- 接入 Retraction Watch / Crossref Event Data
- 整稿批量审稿与投稿前自检插件
- 扩展多学科统计 / 图表复算与图像查伪
- 引用可信度评分与期刊工作流集成